Anleitung Pronomen-Annotation: Goldstandard

1. Worum es geht

Für jedes Pronomen wird von Hand eingetragen, **welche Figur gemeint ist**. Damit wird später gemessen, wie gut mein Modell Pronomen durch den richtigen Figurennamen ersetzen kann.

2. Wie ausgefüllt wird

Bearbeitet werden **ausschließlich** die zwei letzten (gelben) Spalten: `referent_gold` (Pflicht) und `kommentar` (optional). Alle anderen Spalten bleiben unangetastet.

Welches Pronomen ist gemeint? Die Spalte **`satz_markiert`** zeigt es: Das Zielpronomen ist mit ****…**** hervorgehoben. Das ist wichtig, weil über die Hälfte der Sätze mehrere Pronomen enthält (bis zu sieben); es zählt immer nur das markierte.

Was in `referent_gold` eingetragen wird:

Zwei Kontextspalten stehen zur Verfügung. `satz_markiert` zeigt den Satz mit dem hervorgehobenen Pronomen, `block_markiert` zusätzlich die drei bis vier zusammenhängenden Sätze, aus denen der Satz stammt. Weil Pronomen meist zurückverweisen, enthält der Einzelsatz den Bezug häufig nicht: Bei rund 29 Prozent der Einheiten steht davor kein möglicher Bezug im Satz, im Blockkontext sind es nur noch 10 Prozent. Bleibt auch dort unklar, worauf sich das Pronomen bezieht, hilft nur das Nachlesen im jeweiligen Märchen; die Spalte **`erzaehlung`** nennt die Datei, in der du nachschlagen kannst.

Wichtig vorab: Die Zeilen sind **maschinell vorausgewählte Kandidaten**, keine gesicherten Pronomen. Die vorherige Extraktion sammelte großzügig alles ein, was nach einem Pronomen aussieht, darunter zwangsläufig auch Wörter, die gar keine Figur bezeichnen. Erwarte deshalb **nicht**, dass jede Zeile einen Figurennamen bekommt. Prüfe bei jeder Zeile zuerst: Verweist das markierte Wort überhaupt auf eine handelnde Person? Erst wenn ja, wird ein Figurenname eingetragen; andernfalls einer der Sonderwerte. Ein typischer Fall ist „dasselbe" im Sinne von „das Gleiche": grammatisch ein Pronomen, aber es meint eine Aussage, keine Figur, also **`keine_figur`**.

Fall	Eintrag	Beispiel
Pronomen meint eine Figur	**Figurenname, wie er im Märchen genannt wird**	„**er** sprang auf" → `Aladdin`; „**sie** lachte" → `Stiefmutter`
Pronomen meint eine Gruppe	Gruppenname	„**sie** einigten sich" → `Brüder`
Nicht-referentielles *es*	`expletiv`	„**es** zerrte und zupfte"

Fall	Eintrag	Beispiel
Referent ist Ding/Abstraktum/Aussage	`keine_figur`	„Was ist **das** nur?" (das Geräusch); „er sagte **dasselbe**"
Nicht entscheidbar	`unklar`	+ kurze Begründung in `kommentar`
Zeile ist gar kein Pronomen (Extraktionsfehler)	`kein_pronomen`	z. B. falls „die" doch Artikel ist

Regeln zum Figurennamen: die im Märchen übliche **Nennform** verwenden (nicht flektiert: also „`König`", anstatt „Königs"), konsistent innerhalb einer Erzählung; bei mehreren gleichbenannten Figuren (zwei „Mädchen") unterscheidend ergänzen (`Mädchen (jüngere)`) und den Fall in `kommentar` notieren.

Kontext nutzen, ausdrücklich erwünscht: Zum Auflösen darf das **ganze Märchen** gelesen werden. Das ist kein Schummeln: Das System sieht im Einsatz ebenfalls den Volltext.

3. Technische Spielregeln (wichtig, sonst ist die Datei unauswertbar)

Grundregel: Die Einträge entstehen von Hand. Sprachmodelle, Übersetzungs- oder Auswertungswerkzeuge dürfen zum Ausfüllen von `referent_gold` nicht herangezogen werden, auch nicht teilweise und auch nicht „nur zur Vorbereitung". Der Grund ist kein Misstrauen, sondern der Zweck der Erhebung: Diese Daten dienen als Maßstab, an dem ein Sprachmodell gemessen wird. Stammen die Referenzen selbst aus einem Sprachmodell, wird Maschine gegen Maschine geprüft, das Ergebnis ist zirkulär und der Aufwand aller Beteiligten war vergebens.

Unsicherheit ist ausdrücklich erlaubt und erwünscht. Wenn du bei einer Einheit nicht weiterkommst, trag **`unklar`** ein und schreib die Frage in die Spalte **`kommentar`** derselben Zeile. Eine ehrliche Lücke ist für das Projekt wertvoll, eine geratene oder maschinell erzeugte Antwort schädlich.

4. Bitte beachte:

1. **In Excel arbeiten, gelbe Spalten ausfüllen.** Nur `referent_gold` (Dropdown oder Freitext) und `kommentar` sind editierbar; der Rest ist schreibgeschützt. **Den Blattschutz nicht aufheben**; er verhindert nur versehentliches Verrutschen von Sätzen und IDs.
2. **Als `.xlsx` speichern**
3. **Keine Zeilen löschen, sortieren oder einfügen.** Filtern ist erlaubt, falls nötig.
4. **`satz`/`satz_markiert` nicht „korrigieren"**, auch wenn die Tokenisierung ungewohnt aussieht (Leerzeichen vor Satzzeichen sind Absicht).
5. Zweifelsfälle mit **Regelcharakter** in die Spalte **`kommentar`** derselben Zeile schreiben.